

UNIVERSIDAD NACIONAL DE COLOMBIA

REDES NEURONALES: ARQUITECTURAS Y APLICACIONES

Proyecto final (aplicado)

Comparación de modelos estadísticos y de redes neuronales interpretables en clasificación binaria

Estudiante

Hernán Supelano Vega
Maestría en Ciencias-Estadística
hsupelanov@unal.edu.co

Profesor

Arles Rodriguez

11 de junio de 2026

1. Introducción

Los modelos estadísticos tradicionales, como los Modelos Lineales Generalizados (**GLM**) y los Modelos Aditivos Generalizados (**GAM**), permiten analizar el efecto de cada variable sobre la respuesta, pero no pueden representar patrones complejos en los datos, lo que limita su desempeño predictivo frente a modelos más sofisticados.

Por otro lado, los modelos como las redes neuronales multicapa (**MLP**) pueden capturar relaciones complejas entre las variables y alcanzar una alta capacidad predictiva; sin embargo, es difícil interpretar cómo las variables de entrada influyen en las decisiones del modelo. Hasta hace poco surgieron propuestas como la de los Modelos Aditivos Neuronales (**NAM**), los cuales incorporan la capacidad de aprendizaje de las redes neuronales dentro de una estructura aditiva que facilita la interpretación de los efectos de las variables.

En el presente trabajo (disponible en https://github.com/HernanSV/Redes_Neuronales) en los archivos `GLM_GAM_MLP.html` y `NAM_colab.ipynb`) se comparan los modelos **GLM**, **GAM**, **MLP** y **NAM** en un caso de clasificación binaria, la intención es analizar tanto su capacidad predictiva como su interpretabilidad.

2. Trabajo relacionado

En el artículo de [Doohan, Kook, y Burke \(2026\)](#) se compara el desempeño de los **GAM** y las redes neuronales en problemas reales de modelado predictivo sobre una gran cantidad de datos tabulares y concluyen que las **MLP** tienden a obtener mejores resultados cuando el tamaño de muestra es grande y hay gran cantidad de variables predictoras, pero no existe evidencia suficiente para afirmar que las redes neuronales son superiores a los **GAM** en datos tabulares reales.

Si bien el trabajo resalta la interpretabilidad de los **GAM** cuando las diferencias predictivas son pequeñas (lo que puede inclinar la balanza a su favor), no se realiza una mirada a los modelos **NAM**.

3. Datos

Los datos tomados de www.kaggle.com/datasets/wenruliu/adult-income-dataset serán los considerados para este problema de clasificación binaria. Contienen información acerca de los *ingresos anuales* de **48.842** personas (1: mayores a 50K anuales, 0: menores o iguales a 50K) y también información referente a otras **14** variables, entre ellas la *edad*, *género*, *nivel educativo*, *ocupación*, etc.

4. Modelos

Para el ajuste de los modelos, calibración de hiperparámetros y evaluación del área bajo la curva ROC (AUC) y *Accuracy*, se dividió el conjunto de datos en **entrenamiento** (60 %), **validación** (20 %) y **prueba** (20 %).

4.1. Modelo Lineal Generalizado (GLM)

Se ajustó un Modelo Lineal Generalizado (**GLM**) para respuesta binaria, asumiendo que la variable de interés sigue una distribución Bernoulli. Sea Y_i la respuesta observada para el individuo i , entonces

$$Y_i \stackrel{\text{ind.}}{\sim} \text{Bernoulli}(\mu_i), \quad \text{donde} \quad \mu_i = \mathbb{P}(Y_i = 1),$$

$$\text{logit}(\mu_i) = \log\left(\frac{\mu_i}{1 - \mu_i}\right) = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \cdots + \beta_p x_{ip},$$

donde β_0 corresponde al intercepto, $\beta_1, \dots, \beta_p$ son los coeficientes asociados a las variables explicativas y X_{ij} representa el valor de la variable j para la observación i .

4.2. Modelo Aditivo Generalizado (GAM)

Se ajustó el modelo **GAM** utilizando la librería **mgcv** en R. En particular, se consideró un modelo con respuesta binaria y función de enlace **logit**. Las variables continuas se modelaron mediante funciones suaves $s(\cdot)$ (splines penalizados), mientras que las variables categóricas se incluyeron de forma paramétrica.

El modelo ajustado tiene la forma:

$$Y_i \stackrel{\text{ind.}}{\sim} \text{Bernoulli}(\mu_i), \quad \text{donde} \quad \mu_i = \mathbb{P}(Y_i = 1),$$
$$\text{logit}(\mu) = \beta_0 + s_1(x_1) + s_2(x_2) + \dots + s_m(x_m) + \mathbf{z}^\top \boldsymbol{\beta},$$

donde $s_j(\cdot)$ son funciones suaves estimadas a partir de los datos y $\mathbf{z}$ representa el vector de variables categóricas incluidas en el modelo.

4.3. Red neuronal multicapa (MLP)

Se ajustó una red neuronal multicapa (**MLP**) para la clasificación binaria. Para la exploración de hiperparámetros se recurrió a una grilla y se fijaron los valores que maximizaron el área bajo la curva ROC (AUC) en el conjunto de datos de validación. Esta es la configuración del modelo:

Parámetro	Valor
Capas ocultas	2
Neuronas por capa	128, 64
Activación capas ocultas	ReLU
Activación salida	Sigmoide
Regularización	$\lambda_{L_2} = 0.001$
Optimizador	Adam
Tasa de aprendizaje	0.001
Tamaño de lote	64
Máximo de épocas	70
Parada temprana	Paciencia = 20

Cuadro 1: Configuración de la red neuronal multicapa (MLP).

4.4. Modelo Aditivo Neuronal (NAM)

El **NAM**, introducido en [Agarwal y cols. \(2021\)](#) e implementado en `Python` con ayuda del paquete `dnamite`, es una extensión de los modelos **GAM** que utiliza redes neuronales para modelar relaciones no lineales entre cada variable predictora y la respuesta. El modelo es:

$$\text{logit}(\mu) = \beta_0 + f_1(x_1) + f_2(x_2) + \dots + f_p(x_p), \quad \text{donde} \quad \mu = \mathbb{P}(Y = 1)$$




Figura 1: Arquitectura NAM para clasificación binaria

5. Resultados

5.1. Selección de variables

Variable	Tipo	MLP	GLM	GAM	NAM
age	Continua	Sí	Sí	Sí	Sí
fnlwgt	Continua	Sí	Sí	Sí	No
education_num	Continua	Sí	No	No	Sí
capital_gain	Continua	Sí	Sí	Sí	Sí
capital_loss	Continua	Sí	Sí	Sí	Sí
hours_per_week	Continua	Sí	Sí	Sí	Sí
workclass	Categórica	Sí	Sí	No	No
education	Categórica	Sí	Sí	Sí	No
marital_status	Categórica	Sí	Sí	Sí	No
sex	Categórica	Sí	Sí	Sí	No
relationship	Categórica	Sí	Sí	Sí	Sí
race	Categórica	Sí	Sí	Sí	No
occupation	Categórica	Sí	Sí	Sí	Sí
native_country	Categórica	Sí	Sí	Sí	No

Cuadro 2: Selección de variables por modelo

5.2. Capacidad predictiva




Figura 2: Curvas ROC (test)

Modelo	AUC	Accuracy
GLM	0.9115	0.8608
GAM	0.9195	0.8629
MLP	0.9201	0.8656
NAM	0.9270	0.8707

Figura 3: Comparación de métricas (test)

5.3. Interpretabilidad

Puesto que el modelo que presentó mejor capacidad predictiva fue el **NAM**, mostraremos lo que nos dice este modelo acerca del efecto de las variables seleccionadas en la respuesta.

5.4. Importancia de las variables




Figura 4: Importancia de cada variable (NAM)

5.5. Efecto de las variables continuas sobre la respuesta




Figura 5: Efecto de las variables continuas (NAM)

Podemos ver en el gráfico de la variable **age** que esta tiene una relación no lineal con la respuesta (**Ingreso**). Personas menores de 20 años tienen menor probabilidad de tener ingresos altos. La probabilidad de poseer altos ingresos aumenta rápidamente entre los 25 y 45 años. Después de los 50 años el efecto se estabiliza y luego disminuye ligeramente cuando se cumplen los 60 años.

5.6. Efecto de las variables categóricas sobre la respuesta




Figura 6: Efecto de las variables categóricas (NAM)

Podemos ver que el coeficiente asociado para la categoría **Wife** de la variable **relationship** es de aproximadamente 1.9, como $\exp(1.9) \approx 6.7$, entonces podemos afirmar que una persona que sea *esposa* de alguien, tiene 6.7 veces mayor chance de poseer ingresos por encima de los 50K respecto a alguien que no lo sea.

6. Conclusiones del estudio

- De acuerdo a los resultados obtenidos con la muestra *test* del conjunto de datos de interés, los modelos neuronales muestran un mejor desempeño predictivo que los modelos estadísticos tradicionales.
- Los modelos **GLM** y **GAM** tuvieron menor rendimiento predictivo, pero ofrecen mayor claridad en la interpretación y son eficientes computacionalmente.
- El **NAM** se destaca en ambos apartados, pues logra el mejor desempeño en AUC y *accuracy*, y además mantiene una estructura aditiva interpretable. También es el modelo más parsimonioso, pues usó el subconjunto más pequeño de variables. Quizá su parsimonia explique el porqué de su mejora en la generalización con respecto a los otros modelos ajustados.

Dado que las diferencias de desempeño no son muy amplias, la elección del modelo también debe considerar interpretabilidad y complejidad, no solo precisión.

Referencias

- Agarwal, R., Melnick, L., Frosst, N., Zhang, X., Lengerich, B., Caruana, R., y Hinton, G. (2021). *Neural additive models: Interpretable machine learning with neural nets*. Descargado de <https://arxiv.org/abs/2004.13912>
- Doohan, J., Kook, L., y Burke, K. (2026). *Comparison of generalised additive models and neural networks in applications: A systematic review*. Descargado de <https://arxiv.org/abs/2510.24601>